

Geração de imagens artificiais e quantização aplicadas a problemas de classificação

Gabriela Salvador Thumé

Orientador: Prof. Dr. Moacir Antonelli Ponti

Co-orientador: Prof. Dr. João do Espírito Santo Batista Neto

Instituto de Ciências Matemáticas e de Computação
Universidade de São Paulo

29 de abril de 2016



Conselho Nacional de Desenvolvimento
Científico e Tecnológico



Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

- Pré-processamento
- Desbalanceamento de classes
- Extração de características

3 Quantização de imagens

4 Geração de imagens artificiais

5 Resultados

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que não são suficientes para a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que não são suficientes para a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que não são suficientes para a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que não são suficientes para a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Motivação

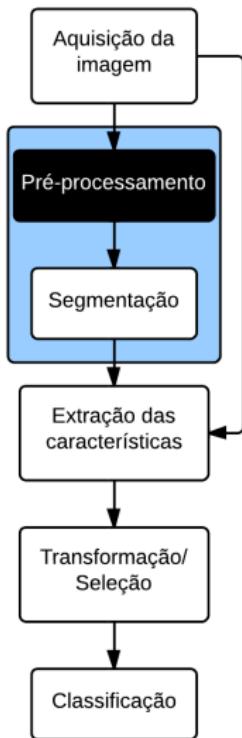


Figura: Etapas canônicas do reconhecimento de padrões.

Motivação

- ▶ Maior esforço ao operar no espaço de características já obtidas;
- ▶ Transformações do espaço ou sistemas complexos de classificação para lidar com as deficiências das características extraídas;
- ▶ Características que podem ser exploradas além dos métodos clássicos;
- ▶ Investigar métodos de processamento e preparação de imagens antes da extração.

Motivação - Características Latentes

- ▶ Justificado o uso de métodos de processamento e preparação de imagens antes da extração;
- ▶ Podem revelar características latentes, não visíveis nas imagens originais;
- ▶ Foco: *revelar características que possam melhor descrever certas classes, utilizando algoritmos sobre as imagens originais.*

Motivação

- ▶ 98% de acurácia após pré-processamento e segmentação (Rocha et al., 2010);
- ▶ Quantização pode impactar a classificação (Kanan e Cottrell, 2012);
- ▶ Quantização permite obter vetores de características mais compactos e com maior capacidade de discriminação entre classes (Ponti et al., 2014);

Continuação.

Motivação - Desbalanceamento de classes

- ▶ Diferença entre o número de exemplos disponíveis;
- ▶ Imagens representam eventos importantes mas menos frequentes;
- ▶ Obstáculo, métodos de transformação do espaço e de classificação assumem que a base está balanceada;
- ▶ Foco: *geração de imagens artificiais a partir do processamento de características das imagens da classe minoritária.*



Figura: Imagem artificialmente gerada.

Hipóteses

Métodos de pré-processamento

- ▶ Evidenciar características latentes que aumentem a variância entre as classes, sem aumentar a variância intra-classe;
- ▶ Melhorar a classificação.

Geração de imagens artificiais

- ▶ Balancear as classes;
- ▶ Melhorar a acurácia, versus geração de exemplos artificiais no espaço de atributos.

Objetivo Geral

Investigar os métodos de pré-processamento para preparar uma coleção de imagens para a extração de características.

Espera-se obter características latentes e balancear o número de instâncias de diferentes classes.

Objetivos Específicos

- ▶ Analisar:
 - ▶ impacto de métodos canônicos na classificação;
 - ▶ aprendizado de bases comportadas por redes de convolução.
- ▶ Tornar as características latentes visíveis;
- ▶ Gerar imagens artificiais.
 - ▶ Resultados preliminares;
 - ▶ Matriz de características aprendida por uma máquina de Boltzmann restrita para verificar a relevância das imagens geradas e as imagens originais.

Objetivos Específicos

- ▶ Analisar:
 - ▶ impacto de métodos canônicos na classificação;
 - ▶ aprendizado de bases comportadas por redes de convolução.
- ▶ Tornar as características latentes visíveis;
- ▶ Gerar imagens artificiais.
 - ▶ Resultados preliminares;
 - ▶ Matriz de características aprendida por uma máquina de Boltzmann restrita para verificar a relevância das imagens geradas e as imagens originais.

Proposta

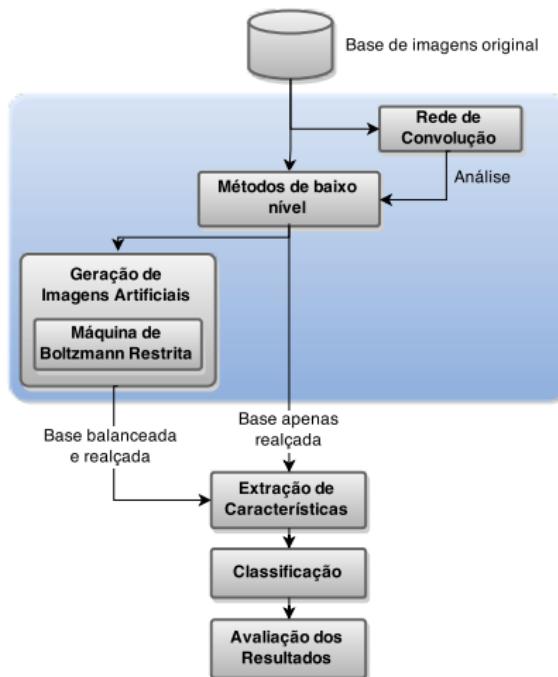


Figura: Estrutura geral desta pesquisa.

Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

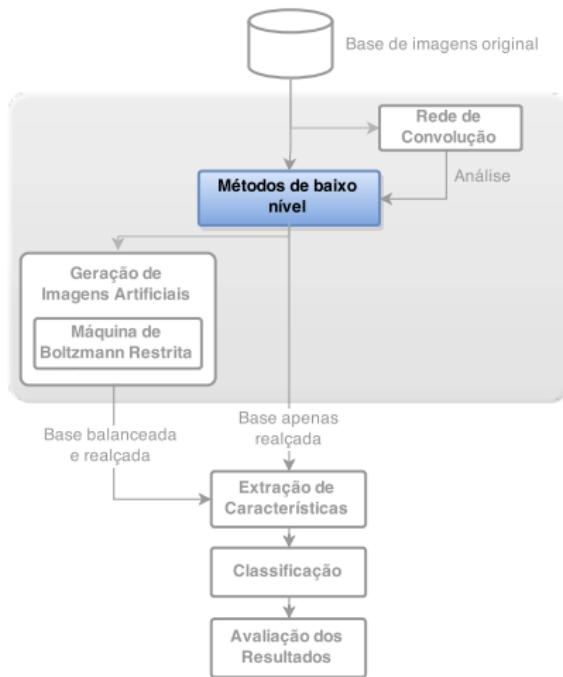
- Pré-processamento
- Desbalanceamento de classes
- Extração de características

3 Quantização de imagens

4 Geração de imagens artificiais

5 Resultados

Pré-processamento de Imagens



Pré-processamento de Imagens

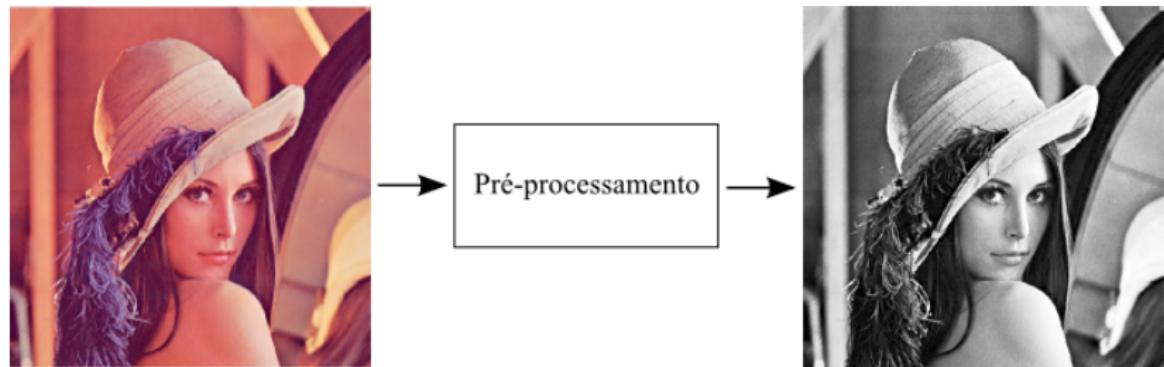


Figura: Conversão em escala de cinza, borramento, realce e de equalização de histograma.

Pré-processamento de Imagens - Convolução

- ▶ Percorre a imagem com um filtro espacial rotacionado em 180°;
- ▶ Cria cada novo pixel com as mesmas coordenadas do centro da vizinhança contendo o valor resultante da filtragem.

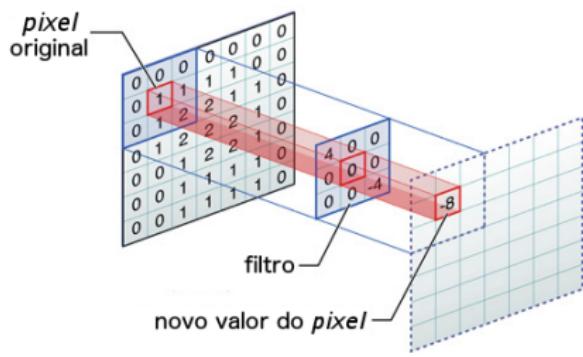
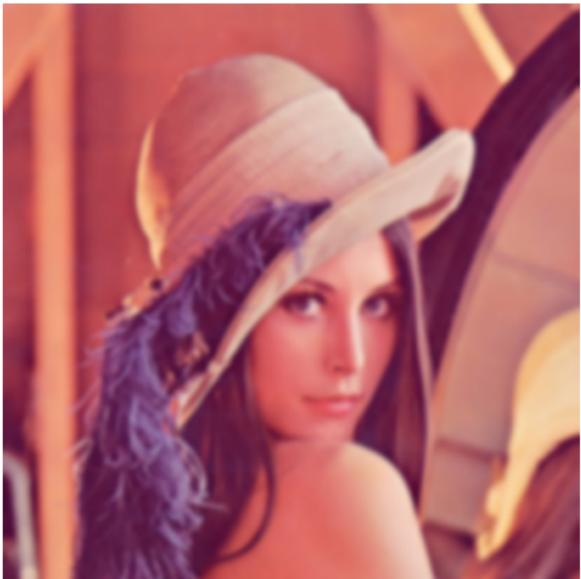


Figura: Convolução com filtro previamente rotacionado.

Pré-processamento de Imagens - Convolução



(a) Original



(b) Filtragem Gaussiana

Pré-processamento de Imagens - Realce



(c) Original



(d) Unsharp masking

Pré-processamento de Imagens - Quantização



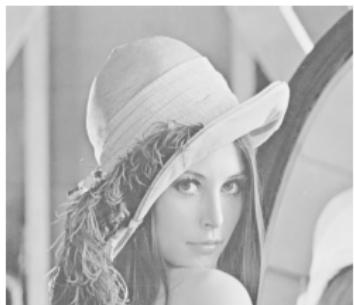
(e) Original



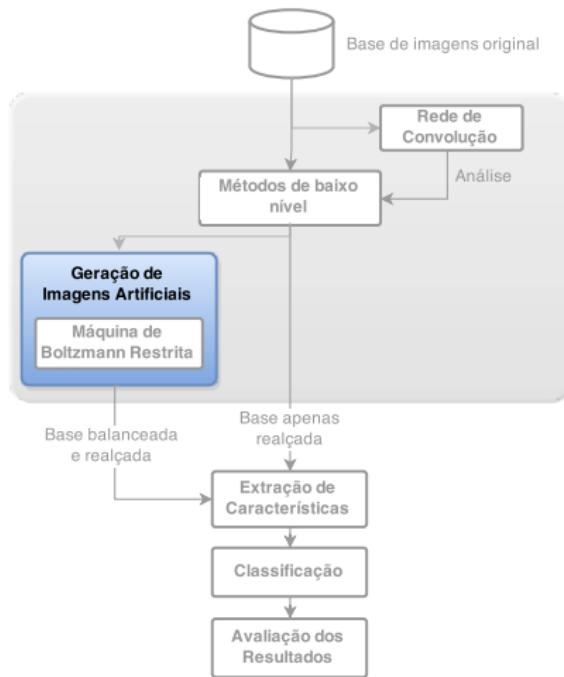
(f) Intensidade'



(g) Gleam



Desbalanceamento de classes



Desbalanceamento de classes

- ▶ Número desbalanceado de exemplos. Majoritárias x minoritárias.
- ▶ Abordagens:
 - ▶ *Modificar métodos de aprendizagem:* adicionar funções de custo na classificação;
 - ▶ *Pré-processamento ao reamostrar os dados:*
 - ▶ Aumentar a minoritária;
 - ▶ Diminuir a majoritária.

Desbalanceamento de classes - Subamostragem

- ▶ Diminuir o número de elementos do conjunto;
- ▶ Podem remover informações essenciais dos dados originais;
- ▶ Eliminar elementos distantes da fronteira de decisão;
- ▶ Normalmente apresentam resultados piores.

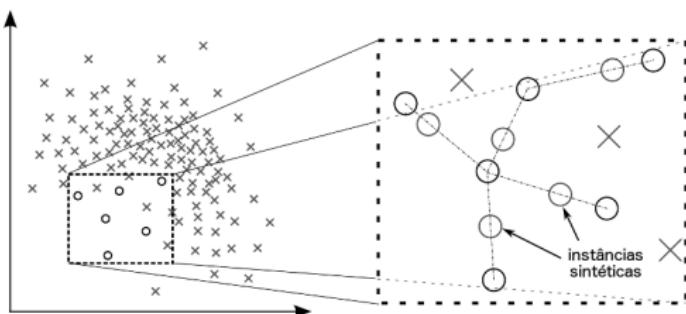
Desbalanceamento de classes - Sobreamostragem

- ▶ Aumentar o número de elementos;

SMOTE

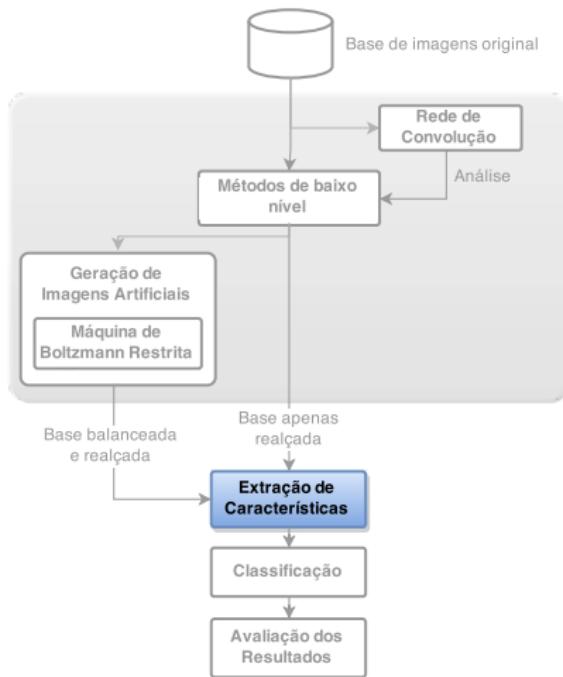
- ▶ Multiplica a diferença entre o vetor de características de um elemento e do seu vizinho mais próximo por um número $0 \leq x \leq 1$;
- ▶ Adiciona ao vetor original, criando um novo elemento entre os dois vetores originais;
- ▶ Aprendido como exemplo da classe minoritária;
- ▶ Força uma região de decisão maior e mais geral;

Desbalanceamento de classes - SMOTE



- ▶ Rebalancear ao gerar novos elementos, ao invés de replicá-los;
- ▶ Sobre os vetores de características previamente extraídos;
- ▶ (Chawla et al., 2002) **Diferentes estratégias para criar exemplos sintéticos podem melhorar a performance da classificação;**
- ▶ Utilizado para comparação.

Extração de Características



Extração de Características

- ▶ Descrever as informações visuais relevantes em um vetor de características;
- ▶ Entrada para o classificador de padrões;
- ▶ Salientar as diferenças entre imagens de classes distintas e suavizar possíveis diferenças de imagens da mesma classe (Ex. algas - forma).

Textura: suavidade, aspereza e uniformidade. Ex. entropia;

Forma: características externas. Ex. curvatura;

Cor: distribuição espacial de cores na imagem. Ex. histograma.

Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

- Pré-processamento
- Desbalanceamento de classes
- Extração de características

3 Quantização de imagens

4 Geração de imagens artificiais

5 Resultados

Quantização de imagens



Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

- Pré-processamento
- Desbalanceamento de classes
- Extração de características

3 Quantização de imagens

4 Geração de imagens artificiais

5 Resultados

Geração de imagens artificiais



Metodologia - Implementação

- ▶ Biblioteca OpenCV;
- ▶ Linguagens de programação C++ e Python;
- ▶ Código disponível em [https://bitbucket.org/moacirponti/
imagefeatureextraction/overview](https://bitbucket.org/moacirponti/imagefeatureextraction/overview).

Metodologia - Experimentos

- ▶ Explorar algoritmos para evidenciar características relevantes:
 - ▶ Melhorar discriminação entre as classes;
 - ▶ Auxiliar no rebalanceamento.
- ▶ Entrada: imagens originais das coleções disponíveis na literatura;
- ▶ Resultado: medidas estatísticas da classificação.

Metodologia - Análise dos resultados

- ▶ Comparar a classificação:
 - ▶ Base original;
 - ▶ Base realçada pelo método proposto.
- ▶ Comparar os métodos:
 - ▶ Geração artificial;
 - ▶ Técnicas de sobreamostragem disponíveis na literatura, como o SMOTE.

Metodologia - Avaliação da Classificação

Medida F1

Problema da acurácia: minoritária sem resultados corretos.

- ▶ Precisão (exatidão): dos exemplos classificados como positivos, quantos realmente são.

$$P = \frac{VP}{VP + FP}$$

- ▶ Revocação (completude): exemplos positivos corretamente classificados como tal.

$$R = \frac{VP}{VP + FN}$$

$$F1 = 2 \frac{P \cdot R}{P + R}$$

Metodologia - Avaliação da Classificação

Medida F1

Problema da acurácia: minoritária sem resultados corretos.

- ▶ Precisão (exatidão): dos exemplos classificados como positivos, quantos realmente são.

$$P = \frac{VP}{VP + FP}$$

- ▶ Revocação (completude): exemplos positivos corretamente classificados como tal.

$$R = \frac{VP}{VP + FN}$$

$$F1 = 2 \frac{P \cdot R}{P + R}$$

Metodologia - Avaliação dos Vetores

Mahalanobis

- ▶ Distância entre a média e a variância das classes;
- ▶ Quanto maior a distância entre as distribuições das classes melhor;
- ▶ Antes e depois dos processamentos a serem realizados.

Baseia na correlação entre as variáveis e pode ser definida por

$$D_m(x_i) = \sqrt{(x_i - \mu) C^{-1} (x_i - \mu)^T},$$

onde x_i é um vetor de valores, μ a média e C a matriz de covariância.

Metodologia - Avaliação

Teste de Friedman

- ▶ Determinar se há diferença significante entre os resultados gerados;
- ▶ Analisa as performances dos algoritmos e atribui um *rank*;
- ▶ A hipótese nula a ser testada é que não há diferença estatística relevante entre as observações;
- ▶ P-valor indica essa significância (limiar de 0,05).

Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses e Objetivos

2 Contextualização

- Pré-processamento
- Desbalanceamento de classes
- Extração de características

3 Quantização de imagens

4 Geração de imagens artificiais

5 Resultados

Descrição do Experimento

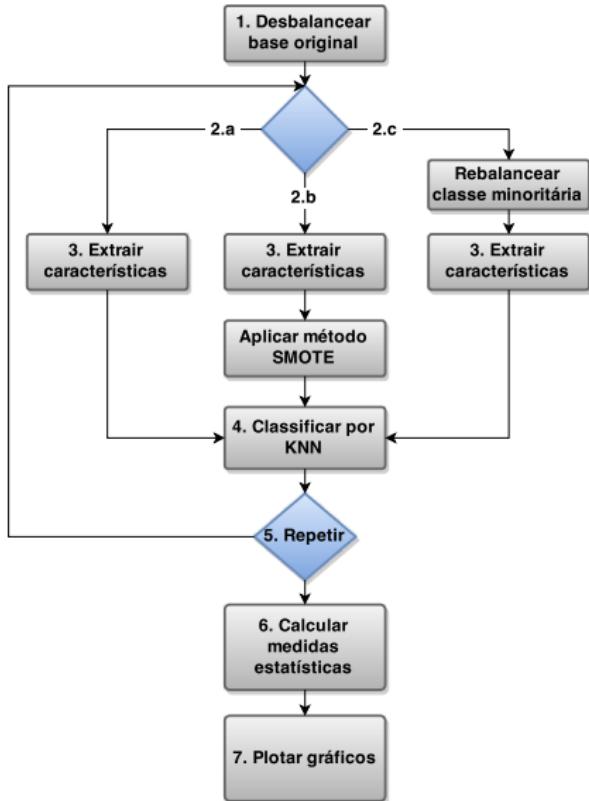


Figura: Fluxo dos resultados preliminares.

Descrição do Experimento

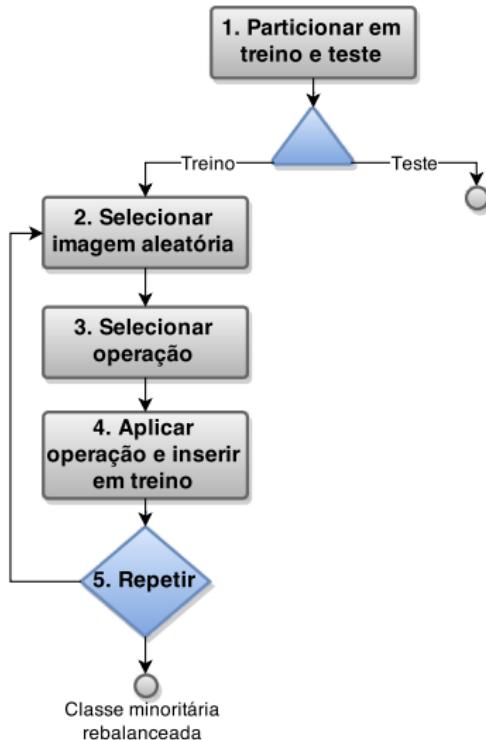


Figura: Fluxo da geração artificial.

Descrição do Experimento

- ▶ Classes praia e montanha da COREL-1000;
- ▶ 50% de teste/treino, com desbalanceamento da classe minoritária em 50, 25, 12 e 6;
- ▶ **Geração artificial:** borramento, adição de ruído, realce, mistura e combinação;
- ▶ **Quantização:** Intensidade para Haralick e MSB para os outros;
- ▶ **Extração de características:** ACC, CCV, BIC, GCH e Haralick;
- ▶ **Classificação** com KNN ($K=1$).

Descrição do Experimento

Classes com alta sobreposição nas características de cor e textura.



Descrição do Experimento - Geração Artificial

Descrição do Experimento - Extração de Características

GCH *Histograma global de cor - N* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, calcula e concatena os histogramas - $2N$.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Calcula dois histogramas - $2N$.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância d um do outro. 1, 3, 5 e 7 - $4N$.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6.

Descrição do Experimento - Extração de Características

GCH *Histograma global de cor - N* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, calcula e concatena os histogramas - $2N$.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Calcula dois histogramas - $2N$.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância d um do outro. 1, 3, 5 e 7 - $4N$.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6.

Descrição do Experimento - Extração de Características

GCH *Histograma global de cor - N* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, calcula e concatena os histogramas - $2N$.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Calcula dois histogramas - $2N$.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância d um do outro. 1, 3, 5 e 7 - $4N$.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6.

Descrição do Experimento - Extração de Características

GCH *Histograma global de cor - N* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, calcula e concatena os histogramas - $2N$.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Calcula dois histogramas - $2N$.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância d um do outro. 1, 3, 5 e 7 - $4N$.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6.

Descrição do Experimento - Extração de Características

GCH *Histograma global de cor - N* (intensidades).

CCV *Vetor de coerência de cor.* Classifica os pixels da imagem em coerentes e incoerentes de acordo com um *threshold*, calcula e concatena os histogramas - $2N$.

BIC *Classificação de pixels de borda e interior.* Mesma cor que seus vizinhos, é pixel de interior. Calcula dois histogramas - $2N$.

ACC *Auto-correlograma de cor.* captura a correlação espacial entre cores idênticas. Probabilidade de encontrar dois pixels com a mesma cor, a uma distância d um do outro. 1, 3, 5 e 7 - $4N$.

Haralick Entropia, homogeneidade, contraste, correlação, probabilidade máxima e uniformidade - 6.

Resultados - Melhor Rebalanceamento

- ▶ Ganho estatístico da medida-F, quando comparado à geração no espaço de atributos;

Figura: Resultado obtido com a operação de combinação.

Resultados - Pior Rebalanceamento

Figura: Piores resultados, obtidos com a adição de ruído.

Resultados

- ▶ Melhores operações

Resultados

- ▶ Teste de Friedman para todas as execuções das melhores operações;
- ▶ P-valor = $4.24E^{-11}$; Hipótese nula rejeitada.

Tabela: Posição média dos algoritmos utilizando Friedman

Algoritmos	Posição
Artificial	1.3863
Smote	1.6136
Original	3.0000

- ▶ Em algumas execuções: Artificial (1), SMOTE (2) e Original (3).

Resultados - Rede de Convolução

<http://caffe.berkeleyvision.org/>

Tabela: Treinamento das classes praia e montanha da base COREL-1000.

Bases	Medida F1
Original não balanceada	0.708
Desbalanceada em 50%	0.577
Rebalanceada	0.677

Artigo publicado na Neurocomputing

Ponti, M.; Nazaré, T; Thumé, G. **Image quantization as a dimensionality reduction procedure in color and texture feature extraction**, submitted to Neurocomputing, 2014.

Neurocomputing 173 (2014) 395–396

Contents lists available at ScienceDirect

 Neurocomputing

 journal homepage: www.elsevier.com/locate/neucom



Image quantization as a dimensionality reduction procedure in color and texture feature extraction

Moacir Ponti ^a, Tiago S. Nazaré, Gabriela S. Thumé

^a Instituto de Ciências Matemáticas e de Computação/Universidade de São Paulo São Carlos, 13560-900 SP Brazil

ARTICLE INFO

Article history:
Received 2 July 2014
Received in revised form
8 April 2015
Accepted 14 April 2015
Available online 1 September 2015

Keywords:
Image quantization
SIFT
Compact features extraction

ABSTRACT

The image-based visual recognition pipeline includes a step that converts color images into images with a single channel, obtaining a color quantized image that can be processed by feature extraction methods. In this work we propose a dimensionality reduction procedure based on image quantization to reduce the size of the feature vectors and to reduce the computational cost of feature extraction methods used in image recognition and classification systems. We show that different quantization methods produce very different results in terms of accuracy. While compared with more complex methods, this procedure allows the feature extraction step to be faster and to reduce the computational cost of the whole visual recognition system. The results indicate that quantization simplify images before feature extraction and dimensionality reduction, producing more compact vectors and reducing system complexity.

© 2015 Elsevier B.V. All rights reserved.

Trabalhos futuros

- ▶ Analisar a memória associativa aprendida com uma máquina de Boltzmann restrita.
 - ▶ Escolher para qual imagem original utilizar, ao invés do método aleatório utilizado nos resultados preliminares;
 - ▶ Verificação da relevância das imagens geradas.

Agradecimentos

Moacir Antonelli Ponti

João do Espírito Santo Batista Neto



*Conselho Nacional de Desenvolvimento
Científico e Tecnológico*



Referências I

Geração de imagens artificiais e quantização aplicadas a problemas de classificação

Gabriela Salvador Thumé

Orientador: Prof. Dr. Moacir Antonelli Ponti

Co-orientador: Prof. Dr. João do Espírito Santo Batista Neto

Instituto de Ciências Matemáticas e de Computação
Universidade de São Paulo

29 de abril de 2016

