

Geração de imagens artificiais e quantização aplicadas a problemas de classificação

Gabriela Salvador Thumé

Orientador: Prof. Dr. Moacir Antonelli Ponti

Co-orientador: Prof. Dr. João do Espírito Santo Batista Neto

Instituto de Ciências Matemáticas e de Computação
Universidade de São Paulo

29 de abril de 2016



Conselho Nacional de Desenvolvimento
Científico e Tecnológico



Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses
- Contribuições

2 Contextualização

- Pré-processamento
- Extração de características
- Desbalanceamento de classes

3 Quantização de imagens

- Experimentos

4 Geração de imagens artificiais

- Experimentos

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que não são suficientes para a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que não são suficientes para a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que não são suficientes para a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Introdução

- ▶ Classificação de imagens;
- ▶ Extração de características;
- ▶ Algoritmos de aprendizado de máquina: modelo de representação;
- ▶ Generalização permite classificar novos exemplos;
- ▶ Características que não são suficientes para a diferenciação entre as classes;
- ▶ Encontrar as características que melhor discriminam as classes.

Motivação

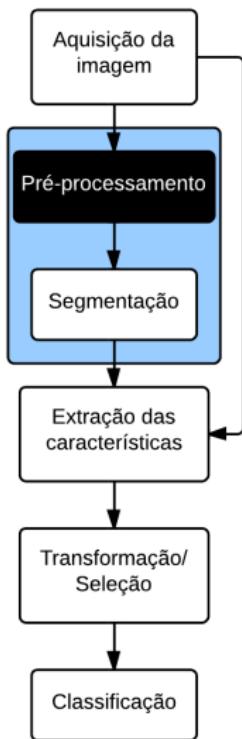


Figura : Etapas canônicas do reconhecimento de padrões.

Motivação

- ▶ Maior esforço ao operar no espaço de características já obtidas;
- ▶ Transformações do espaço ou sistemas complexos de classificação para lidar com as deficiências das características extraídas;
- ▶ Características que podem ser exploradas além dos métodos clássicos;
- ▶ Investigar métodos de processamento e preparação de imagens antes da extração.

Motivação - Características Latentes

- ▶ Justificado o uso de métodos de processamento e preparação de imagens antes da extração;
- ▶ Podem revelar características latentes, que possam melhor descrever certas classes, utilizando algoritmos sobre as imagens originais.

Motivação

- ▶ 98% de acurácia após pré-processamento e segmentação (Rocha et al., 2010);
- ▶ Quantização pode impactar a classificação (Kanan e Cottrell, 2012);
- ▶ Quantização permite obter vetores de características mais compactos e com maior capacidade de discriminação entre classes (Ponti et al., 2014);

Motivação - Desbalanceamento de classes

- ▶ Diferença entre o número de exemplos disponíveis;
- ▶ Imagens representam eventos importantes mas menos frequentes;
- ▶ Obstáculo, métodos de transformação do espaço e de classificação assumem que a base está balanceada;
- ▶ Foco: *geração de imagens artificiais a partir do processamento de características das imagens da classe minoritária.*



Figura : Imagem artificialmente gerada.

Hipóteses

Utilizar um número reduzido de cores

- ▶ Juntamente com um método de quantização apropriado;
- ▶ Antes da extração de características;
- ▶ *Pode permitir obter vetores de características mais compactos e com maior capacidade de discriminação entre classes.*

Geração de imagens artificiais

- ▶ Balancear as classes;
- ▶ Preparação para a extração de características;
- ▶ *Melhorar a acurácia, quando comparada à geração de exemplos artificiais no espaço de atributos.*

Contribuição geral

Investigar os métodos de pré-processamento para preparar uma coleção de imagens para a extração de características.

Observa-se o efeito da quantização de imagens e do balanceamento do número de instâncias de diferentes classes na classificação.

Contribuições específicas

- ▶ Demostrar que é possível obter vetores de características compactos e efetivos ao extrair imagens quantizadas;
 - ▶ Custo computacional baixo;
 - ▶ Reduzindo o tamanho do vetor após a quantização e posterior extração de características;
 - ▶ Redução do tempo de processamento para os métodos de descrição de textura.
- ▶ Demostrar que a geração de imagens artificiais pode contribuir com o balanceamento entre classes.
 - ▶ Melhorando o *F1-Score* resultante de algoritmos de classificação;
 - ▶ Comparando com a geração de exemplos artificiais no espaço de atributos (SMOTE) e à classificação da base original.

Contribuições específicas

- ▶ Demostrar que é possível obter vetores de características compactos e efetivos ao extrair imagens quantizadas;
 - ▶ Custo computacional baixo;
 - ▶ Reduzindo o tamanho do vetor após a quantização e posterior extração de características;
 - ▶ Redução do tempo de processamento para os métodos de descrição de textura.
- ▶ Demostrar que a geração de imagens artificiais pode contribuir com o balanceamento entre classes.
 - ▶ Melhorando o *F1-Score* resultante de algoritmos de classificação;
 - ▶ Comparando com a geração de exemplos artificiais no espaço de atributos (SMOTE) e à classificação da base original.

Contribuições em código e reproduzibilidade

- ▶ Código para a quantização: <http://dx.doi.org/10.5281/zenodo.15932>
- ▶ Código da geração artificial: <https://github.com/GabiThume/msc-src>

Estrutura

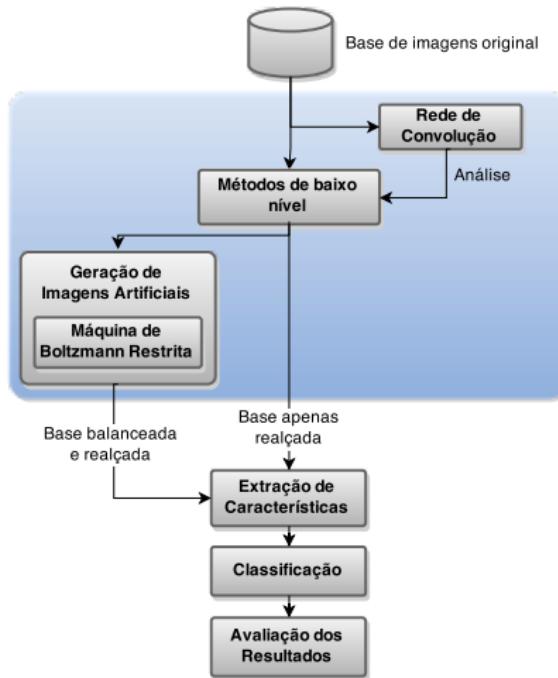


Figura : Estrutura geral desta pesquisa.

Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses
- Contribuições

2 Contextualização

- Pré-processamento
- Extração de características
- Desbalanceamento de classes

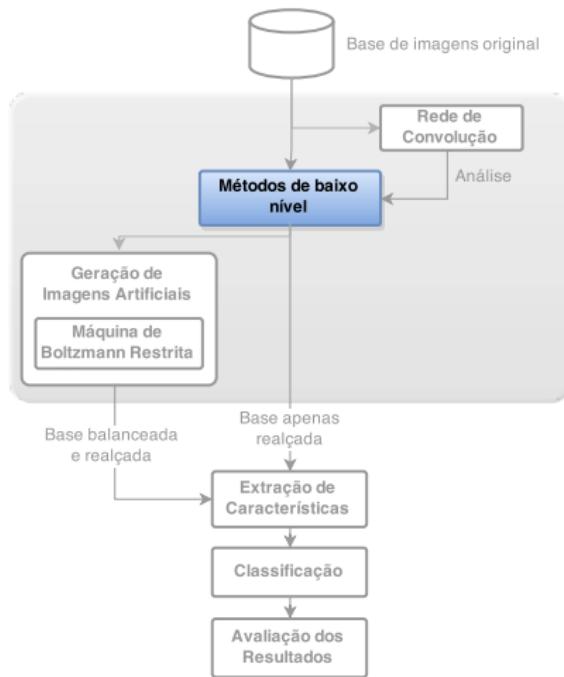
3 Quantização de imagens

- Experimentos

4 Geração de imagens artificiais

- Experimentos

Pré-processamento de Imagens



Pré-processamento de Imagens

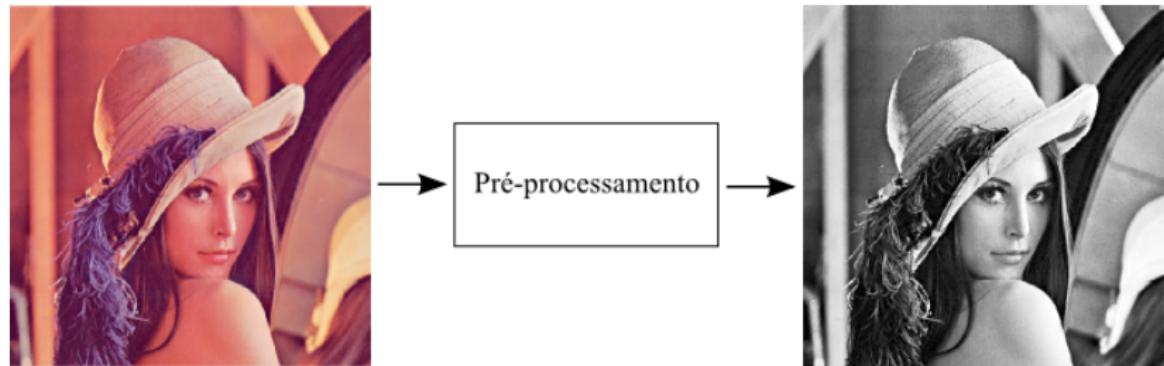


Figura : Conversão em escala de cinza, borramento, realce e de equalização de histograma.

Pré-processamento de Imagens - Convolução

- ▶ Percorre a imagem com um filtro espacial rotacionado em 180°;
- ▶ Cria cada novo pixel com as mesmas coordenadas do centro da vizinhança contendo o valor resultante da filtragem.

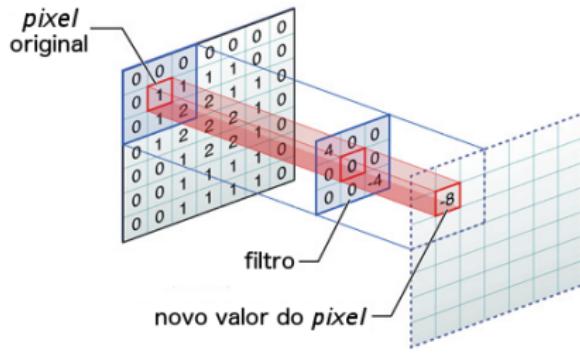
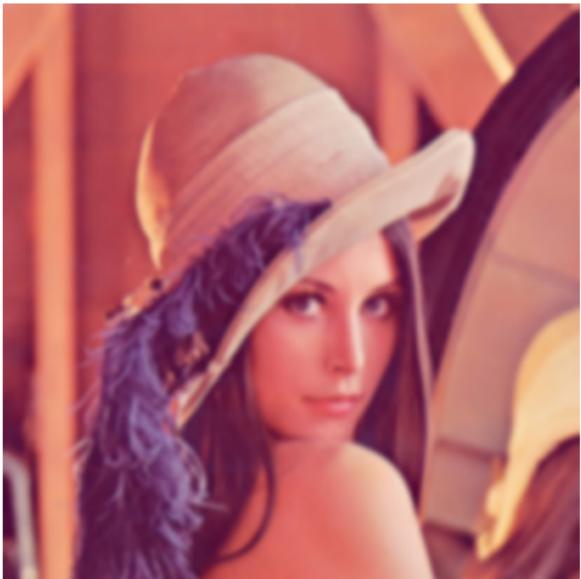


Figura : Convolução com filtro previamente rotacionado.

Pré-processamento de Imagens - Convolução



(a) Original



(b) Filtragem Gaussiana

Pré-processamento de Imagens - Realce

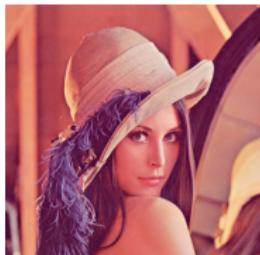


(c) Original

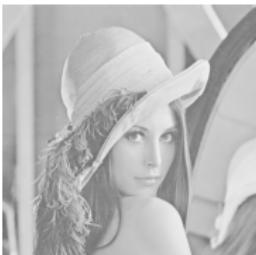


(d) Unsharp masking

Pré-processamento de Imagens - Quantização



(e) Original



(f) Intensidade'



(g) Gleam



(h) Luminância'

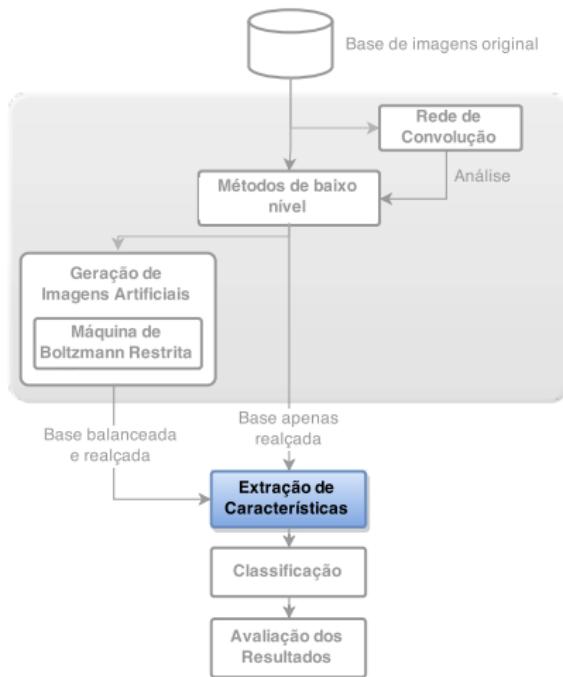


(i) Luma



(j) MSB

Extração de Características



Extração de Características

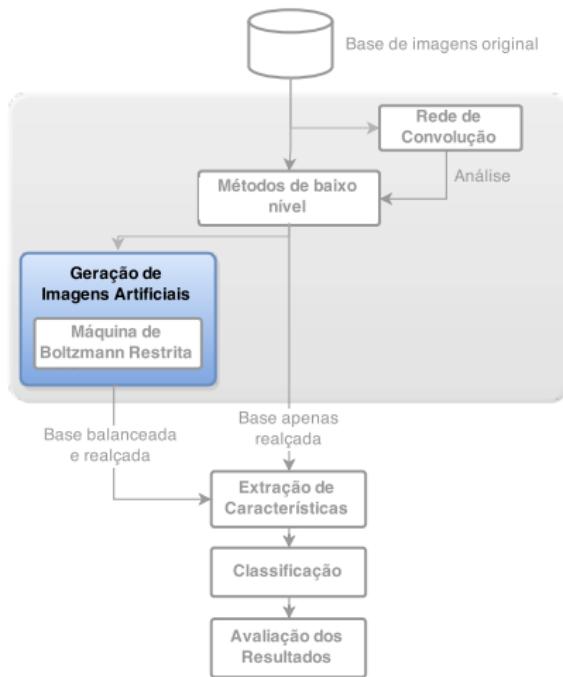
- ▶ Descrever as informações visuais relevantes em um vetor de características;
- ▶ Entrada para o classificador de padrões;
- ▶ Salientar as diferenças entre imagens de classes distintas e suavizar possíveis diferenças de imagens da mesma classe (Ex. algas - forma).

Textura: suavidade, aspereza e uniformidade. Ex. entropia;

Forma: características externas. Ex. curvatura;

Cor: distribuição espacial de cores na imagem. Ex. histograma.

Desbalanceamento de classes



Desbalanceamento de classes

- ▶ Número desbalanceado de exemplos. Majoritárias x minoritárias.
- ▶ Abordagens:
 - ▶ *Modificar métodos de aprendizagem:* adicionar funções de custo na classificação;
 - ▶ *Pré-processamento ao reamostrar os dados:*
 - ▶ Aumentar a minoritária;
 - ▶ Diminuir a majoritária.

Desbalanceamento de classes - Subamostragem

- ▶ Diminuir o número de elementos do conjunto;
- ▶ Podem remover informações essenciais dos dados originais;
- ▶ Eliminar elementos distantes da fronteira de decisão;
- ▶ Normalmente apresentam resultados piores.

Desbalanceamento de classes - Sobreamostragem

- ▶ Aumentar o número de elementos;

SMOTE

- ▶ Multiplica a diferença entre o vetor de características de um elemento e do seu vizinho mais próximo por um número $0 \leq x \leq 1$;
- ▶ Adiciona ao vetor original, criando um novo elemento entre os dois vetores originais;
- ▶ Aprendido como exemplo da classe minoritária;
- ▶ Força uma região de decisão maior e mais geral;

Desbalanceamento de classes - Sobreamostragem

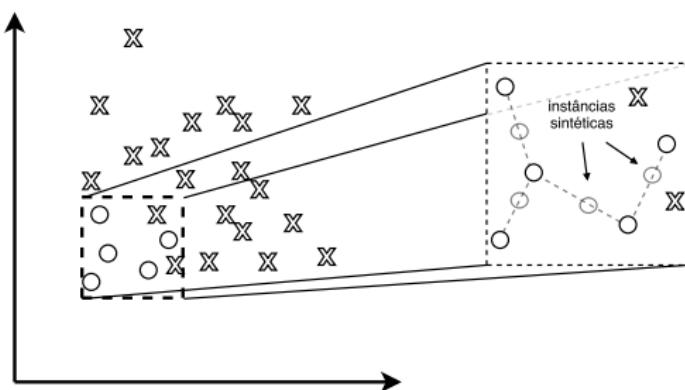
Algorithm 1: SMOTE: método para rebalancear classes

Entrada: Imagem colorida I em formato RGB

Saída: Exemplos sintéticos S

```
1  $N \leftarrow \text{vizinhos}(\text{classe minoritária});$ 
2 para cada exemplo da classe minoritária faça
3    $nn \leftarrow \text{vizinho aleatório de } N;$ 
4    $novo\_elemento \leftarrow \emptyset;$ 
5   para cada característica  $(x, y)$  do exemplo faça
6      $diferença \leftarrow nn(x, y) - exemplo(x, y);$ 
7      $gap \leftarrow \text{número aleatório entre } 0 \text{ e } 1;$ 
8      $novo\_elemento(x, y) \leftarrow exemplo(x, y) + gap * diferença;$ 
9   fim
10   $S \leftarrow S \cup novo\_elemento;$ 
```

Desbalanceamento de classes - SMOTE



- ▶ Rebalancear ao gerar novos elementos, ao invés de replicá-los;
- ▶ Sobre os vetores de características previamente extraídos;
- ▶ (Chawla et al., 2002) **Diferentes estratégias para criar exemplos sintéticos podem melhorar a performance da classificação;**
- ▶ Utilizado para comparação.

Redução de dimensionalidade

Precisa?

Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses
- Contribuições

2 Contextualização

- Pré-processamento
- Extração de características
- Desbalanceamento de classes

3 Quantização de imagens

- Experimentos

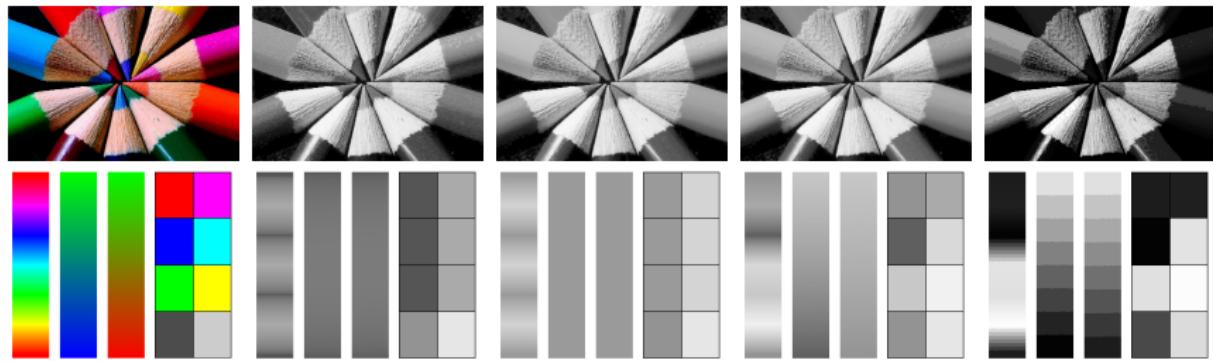
4 Geração de imagens artificiais

- Experimentos

Quantização de imagens

- ▶ O pipeline de reconhecimento de imagens inclui a conversão de imagens coloridas em imagens com apenas um canal ($2^3 = 8$ bits, $2^8 = 256$ intensidades);
- ▶ Após, essas imagens quantizadas são processadas por métodos de extração de características;
- ▶ Essa pesquisa explorou essa etapa para produzir vetores mais compactos.
- ▶ Diferentes parâmetros de quantização combinados com quatro métodos de extração de cor e um de textura.

Quantização de imagens



(k) Original (l) Gleam (m) Intensidade' (n) Luminância' (o) MSB

Figura : A imagem original resultou em versões de um canal de cor com 232 intensidades únicas para o método (e) MSB e 184 intensidades para os demais métodos. Observa-se que os métodos *Luminância'* e MSB conseguiram uma melhor discriminação entre cores.

Quantização de imagens

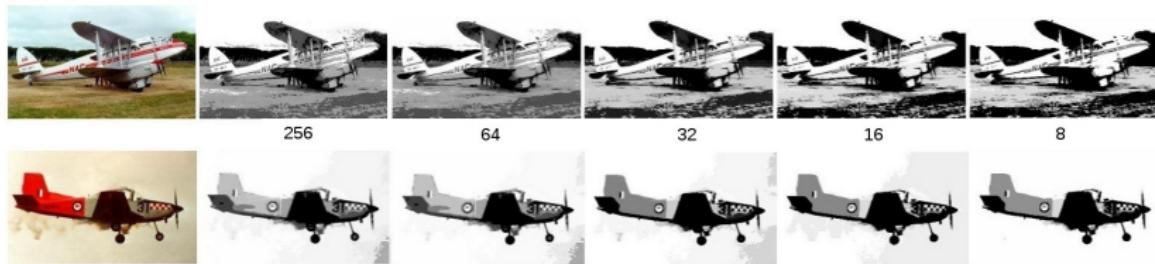


Figura : Exemplo de duas imagens da base de dados *Caltech101-600* com variações no parâmetro de cor utilizando o método MSB. Da esquerda para a direita: imagem original 24-bits e suas versões quantizadas com: 256, 64, 32, 16 e 8 cores.

Experimentos

- ▶ Experimentos utilizando um método de extração de características seguido pela classificação (sem posterior seleção de características);
- ▶ Experimentos utilizando o vetor resultante da concatenação de todos os métodos de extração, seguido pela classificação com e sem a seleção de características.

Experimentos

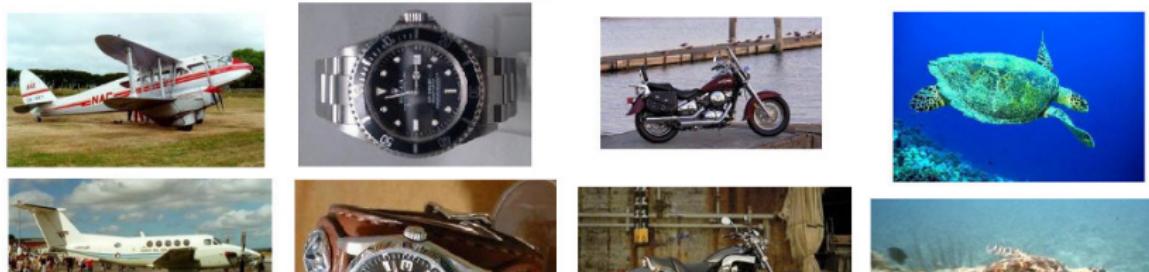


Figura : Fluxo das operações e os métodos utilizados nos experimentos.

Experimentos - Bases de Imagens



(a) Base de imagens Corel-1000



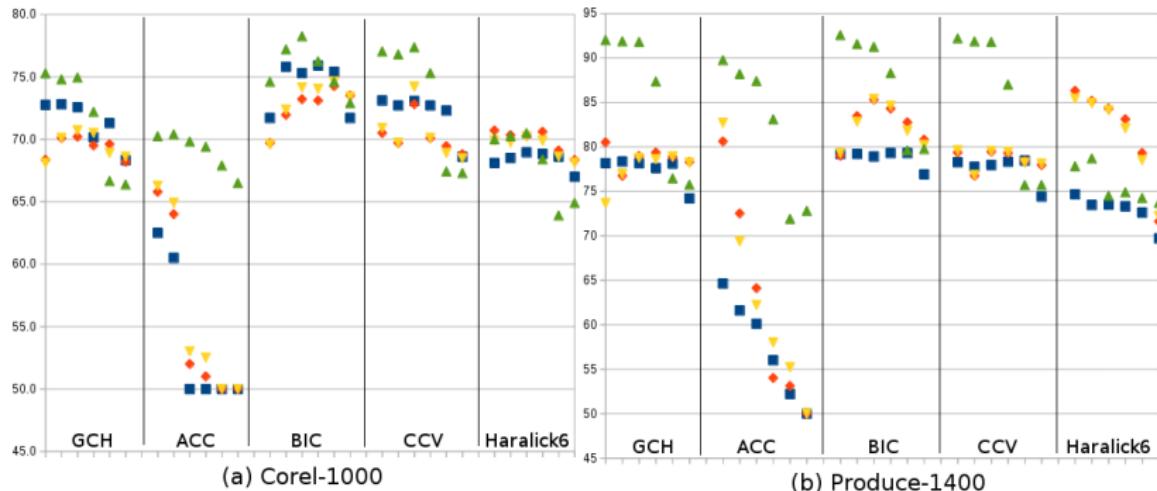
Experimentos — Protocolo

1. **Quantização:** com os métodos *Intensidade', Gleam, Luminância'* e MSB.
2. **Extração de características:** utilizando os métodos e parâmetros escolhidos com base nas recomendações dos artigos que proporam tais métodos:
 - ▶ *Auto Color Correlogram* (ACC): a métrica de distância utilizada entre os pixels $p(x, y)$ e $q(s, t)$ é a tabuleiro de xadrez $D_8(p, q) = \text{Max}(|x - s| + d, |y - t| + d)$ para quatro distâncias $d = 1, 3, 5$ e 7 ;
 - ▶ *Border-Interior Classification* (BIC): com uma vizinhança de quatro pixels;
 - ▶ *Color Coherence Vector* (CCV): adotando um valor de $threshold = 25$ para a classificação dos pixels entre coerentes e incoerentes;
 - ▶ Haralick-6: o pixel vizinho para o qual iniciar a computar a matriz

Experimentos — Resultados

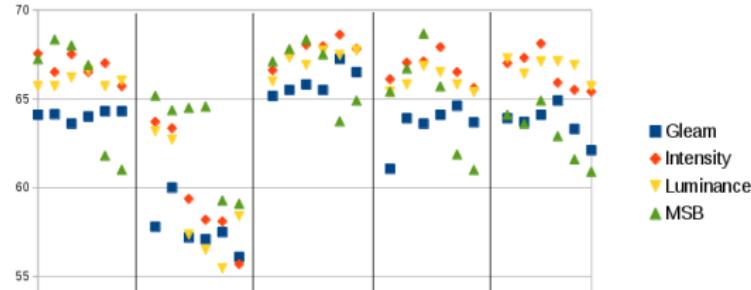
1.

Experimentos — Resultados



(a) Corel-1000

(b) Produce-1400



■ Gleam
◆ Intensity
▽ Luminance
▲ MSB

Experimentos — Resultados

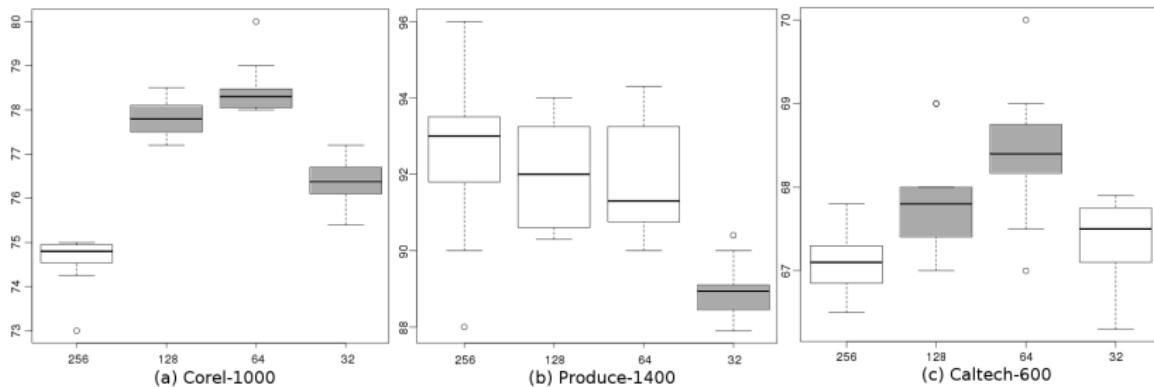


Figura : Resultados de acurácia média da classificação utilizando o método de quantização MSB considerando 256, 128, 64 e 32 cores com o método de extração de características BIC. Os *boxplots* em cinza correspondem às significâncias estatísticas com $p\text{-value} < 0.01$ quando comparado à acurácia de 256 cores.

Experimentos — Resultados

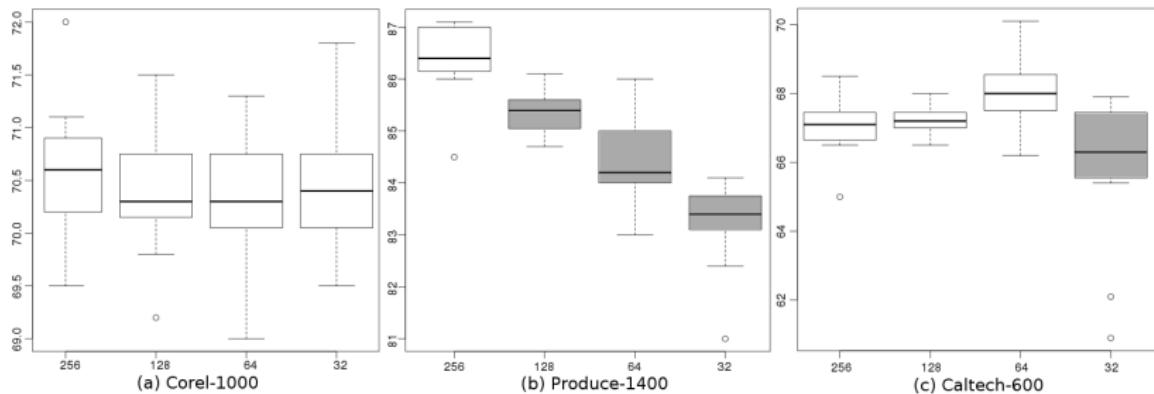


Figura : Acurácia média da classificação após a utilização do método de quantização 'Luminância' considerando 256, 128, 64 e 32 cores com o descriptor Haralick. Os *boxplots* em cinza correspondem às significâncias estatísticas com $p\text{-value} < 0.01$ quando comparado à acurácia de 256 cores

Experimentos — Resultados

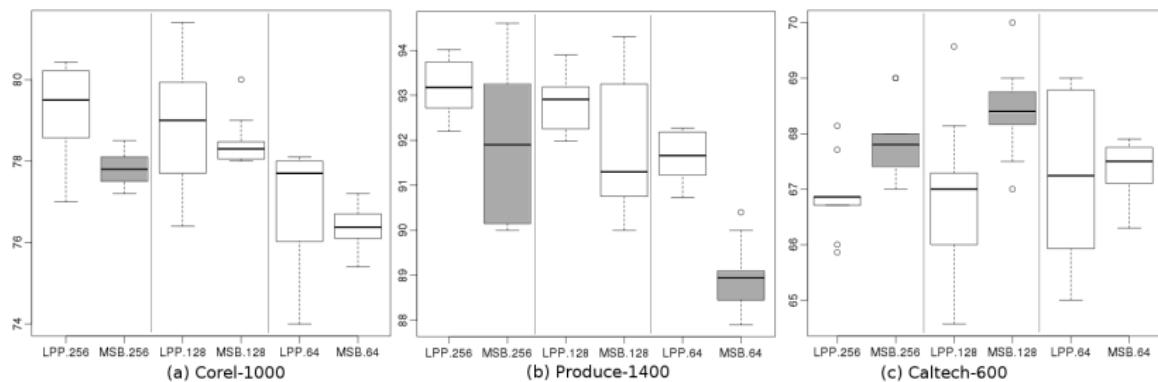


Figura : Resultados de acurácia para os método MSB (quantização), LPP (redução de dimensionalidade) e BIC (extração de características). A comparação do LPP versus MSB foi realizada com a mesma dimensionalidade. Os boxplots em cinza correspondem às significâncias estatísticas com $p < 0.01$ quando comparado a acurácia de 256 cores.

Experimentos — Resultados

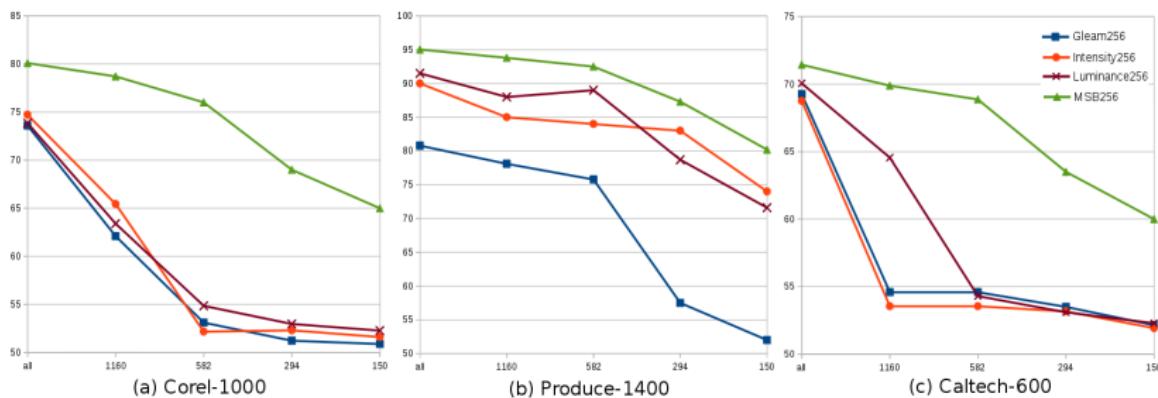


Figura : Comparação da acurácia alcançada com diferentes métodos de quantização: *Gleam*, *Intensidade*', *Luminância*' e *MSB*. Inicialmente as imagens foram convertidas para escala de cinza com esses quatro métodos e foram dadas como entrada para todos os métodos de extração. O vetor de características resultante com $D = 2310$ sofreu então redução da dimensionalidade com o método LPP para $d = 1160, 582, 294$ e 150 .

Experimentos — Resultados

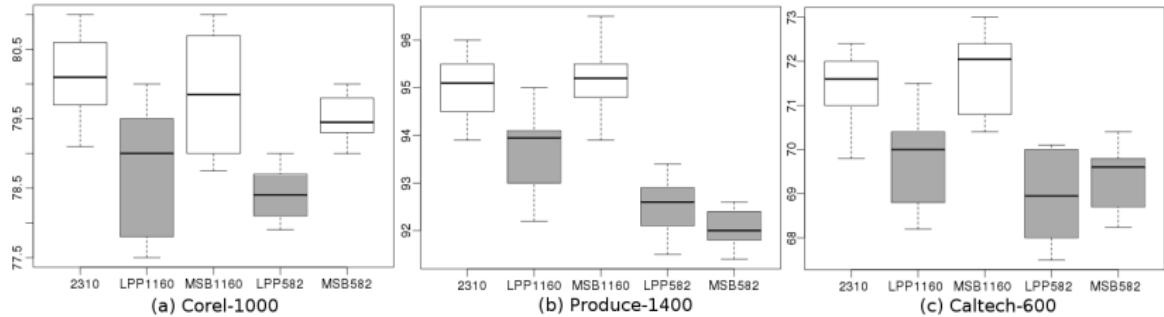


Figura : Comparação da acurácia com o uso da projeção LPP e o método MSB para quantização das imagens com o objetivo de redução de dimensionalidade.

Experimentos — Resultados

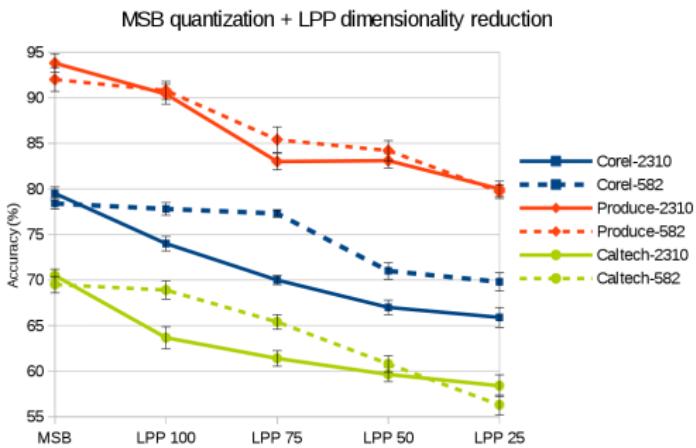


Figura : Resultados para a projeção do LPP sobre o espaço de características produzido pelo método de quantização MSB utilizando 256 ($d = 2310$) e 64 cores ($d = 582$).

Experimentos — Discussão

1. Aplicar a quantização na etapa de pré-processamento causa a redução da dimensionalidade do vetor de características no início do pipeline, beneficiando todas as etapas posteriores;
2. Utilizar um número reduzido de cores pode reduzir significativamente a dimensionalidade, enquanto melhora ou mantém a classificação do sistema;
3. Ao comparar o uso da quantização com a utilização de métodos mais complexos para a redução da dimensionalidade, esse processamento permite uma redução significante, enquanto normalmente preserva ou melhora a acurácia do sistema.

Estrutura da Apresentação

1 Introdução

- Motivação
- Hipóteses
- Contribuições

2 Contextualização

- Pré-processamento
- Extração de características
- Desbalanceamento de classes

3 Quantização de imagens

- Experimentos

4 Geração de imagens artificiais

- Experimentos

Geração de imagens artificiais

- ▶ Compensar a baixa disponibilidade de exemplos de uma determinada classe;
- ▶ Permitir a extração de informações antes não disponíveis nas imagens originais por meio da combinação ou perturbação das imagens de entrada.

Geração de imagens artificiais

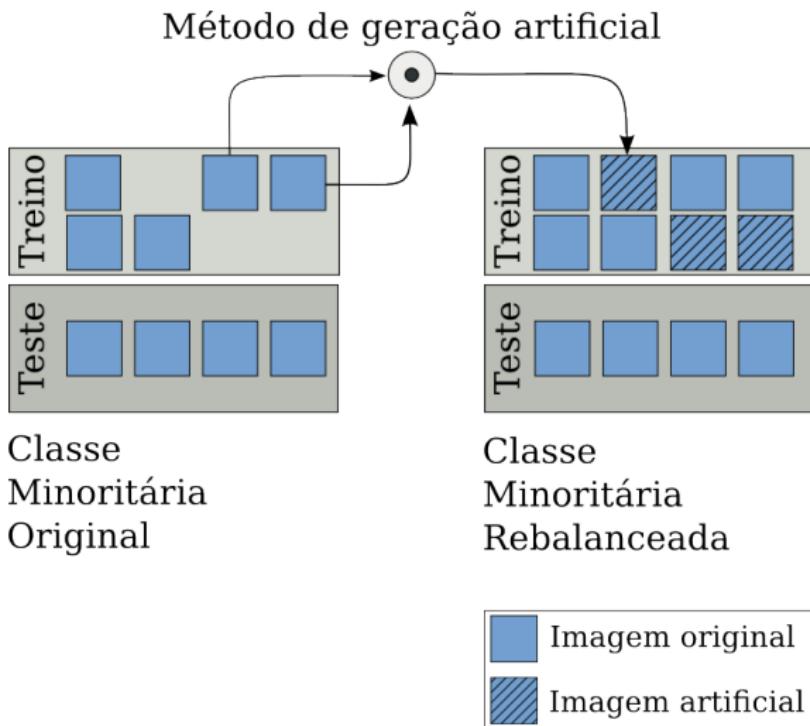


Figura : Geração artificial da classe minoritária para rebalancear a base

Geração de imagens artificiais — Métodos

- ▶ Borramento;
- ▶ Aguçamento;
- ▶ Composição;
- ▶ Mistura ponderada;
- ▶ Mistura limiarizada;
- ▶ Mistura saliente;
- ▶ SMOTE visual;
- ▶ Adição de ruído.

Geração de imagens artificiais — Borramento



(a) Original



(b) Imagem artificial

Figura : Geração artificial utilizando *borramento* com filtro bilateral. A imagem (b) possui detalhes borrados, porém preservando as bordas.

Geração de imagens artificiais — Aguçamento



(a) Original



(b) Imagem artificial

Figura : Geração artificial utilizando *unsharp masking*. A imagem resultante (b) apresenta saliência nas transições de intensidade.

Geração de imagens artificiais — Adição de ruído



(a) Original



(b) Imagem artificial

Figura : Geração artificial utilizando *adição de ruído* de Poisson. Regiões claras de (b) apresentam mais ruído que as regiões escuras.

Geração de imagens artificiais — SMOTE visual



(a) Original



(b) Original



(c) Imagi-

Figura : Geração artificial utilizando o método SMOTE no espaço visual.
É possível notar a sobreposição de uma “sombra” da Figura (b) em (a).

Geração de imagens artificiais — Mistura ponderada



(a) Original



(b) Original



(c) Imagem artificial

Figura : Geração artificial utilizando uma *mistura ponderada* de duas imagens. A imagem (c) representa a mistura de (a) e (b).

Geração de imagens artificiais — Mistura limiarizada



(a) Original



(b) Original



(c) Imagem artificial

Figura : Geração artificial utilizando uma *mistura limiarizada* de duas imagens. A imagem resultante (c) é uma composição do *foreground* da primeira imagem sobre o *background* da segunda.

Geração de imagens artificiais — Mistura saliente



(a) Original



(b) Original



(c) Imagem artificial

Figura : Geração artificial utilizando a *mistura saliente* de duas imagens. A imagem resultante (c) apresenta a região saliente de (b) sobreposta em (a).

Geração de imagens artificiais — Composição

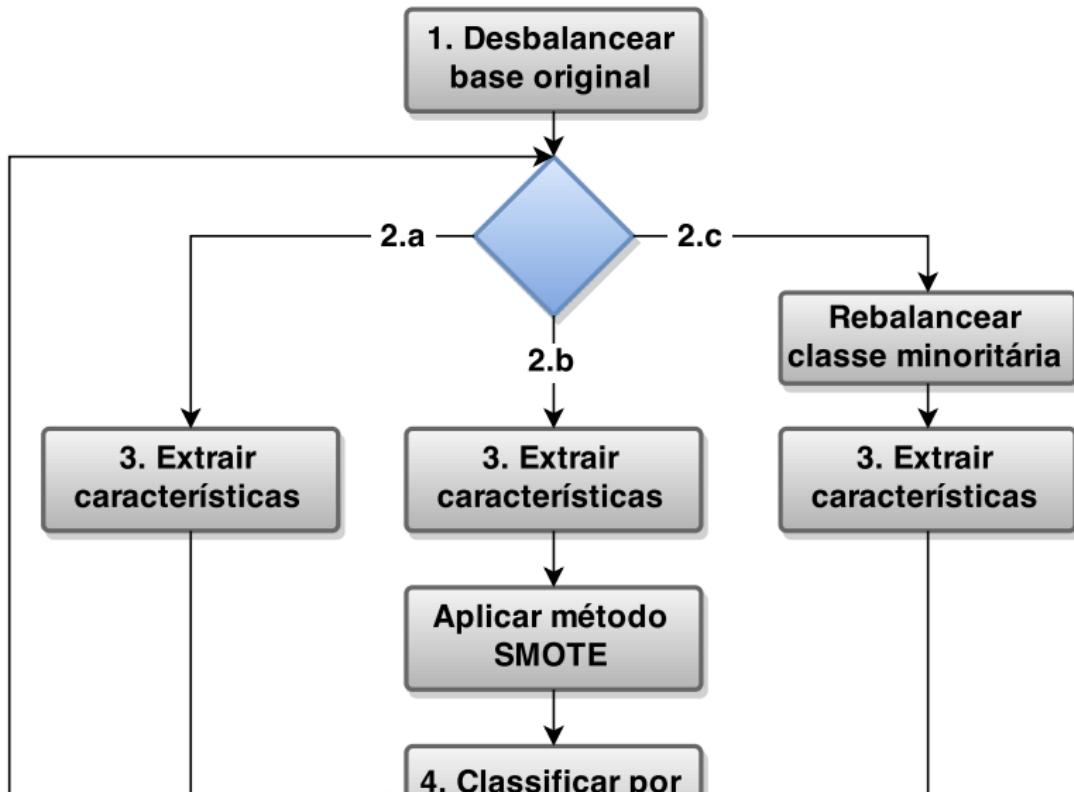


Figura : Geração artificial utilizando uma *composição* de imagens. Várias imagens, dispostas em um mosaico, formam a imagem resultante. Cada célula do mosaico sofre uma operação, sorteada no momento da geração da imagem.

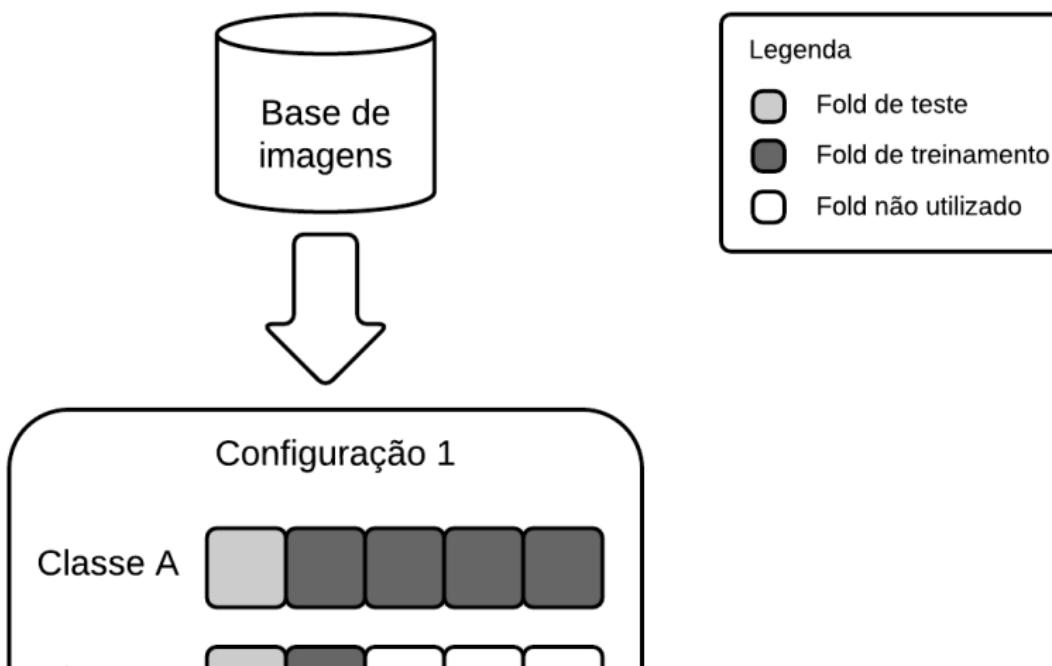
Experimentos

- ▶ Comparar a classificação:
 - ▶ Base original;
 - ▶ Base realçada pelo método proposto.
- ▶ Comparar os métodos:
 - ▶ Geração artificial;
 - ▶ Técnicas de sobreamostragem disponíveis na literatura, como o SMOTE.

Experimentos



Experimentos



Experimento: duas classes discriminadas



Figura : Classes *Horse* e *Elephant* utilizadas no experimento. São duas classes bem discriminadas com 100 imagens cada, originalmente da base de imagens Corel-1000.

Protocolo

- 1. Imagens originais:** classes *Horse* e *Elephant* da base de imagens Corel-1000 [?]. A principal característica dessas imagens é a diferença de cores, contendo pequeno grau de sobreposição.
- 2. Desbalanceamento:** para o sub-experimento de visualização, cada classe foi dividida em 50% para treino e 50% para teste, de maneira aleatória. Após, a classe *Horse* sofreu remoção de 50% do seu conjunto de treino, tornando-a desbalanceada. Já para a análise estatística do experimento, todas as 40 configurações de *folds* com $k = 5$ foram realizadas (padronização anteriormente descrita na Figura ??).
- 3. Método para geração artificial:** para a visualização do espaço de características foi utilizado o método de *mistura* de duas imagens originais, exemplificado na Figura ??.

Descrição do Experimento



(a) Original



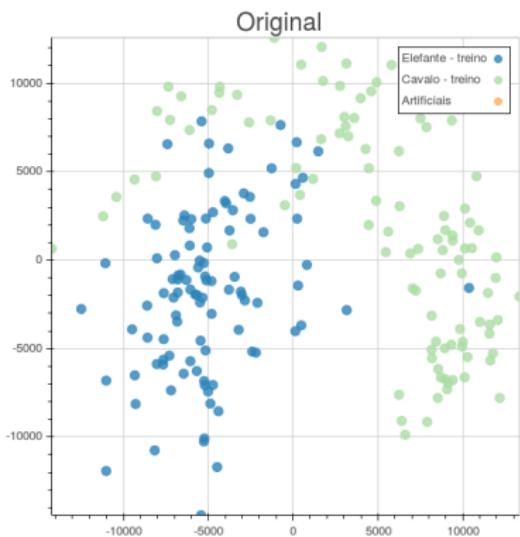
(b) Original



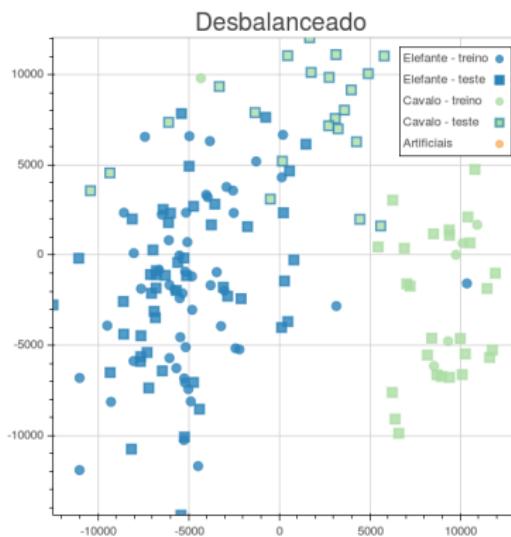
(c) Imagem artificial

Figura : Exemplo da geração artificial de imagens com o método de *mistura* para as classes *Elephant* e *Horse* da base Corel-1000. A imagem resultante (c) é composta pela mistura de (a) e (b).

Experimento



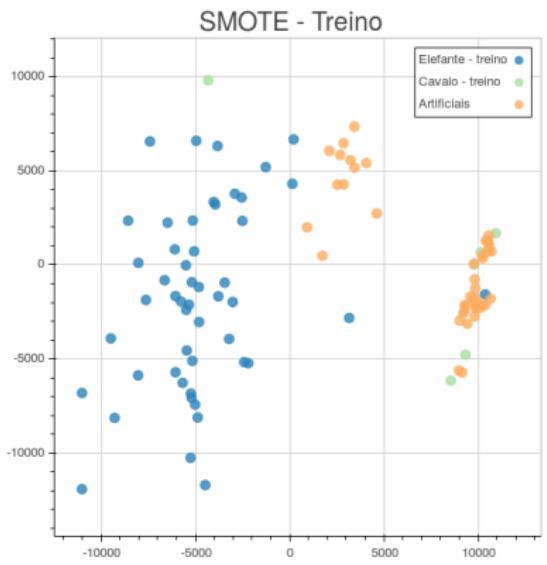
(a) Original



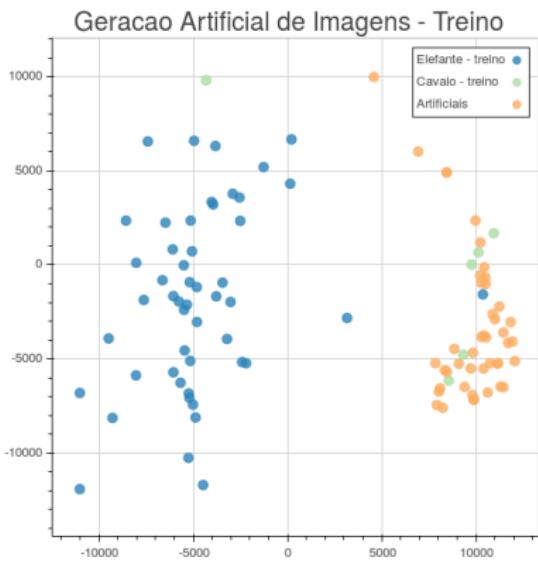
(b) Desbalanceado

Figura : À esquerda a projeção dos dois componentes principais obtidos com a aplicação de PCA nas classes *Elephant* — em azul — e *Horse* — em verde. À direita, as mesmas classes após a remoção de 50% das

Experimento



(a) SMOTE



(b) Geração artificial de imagens

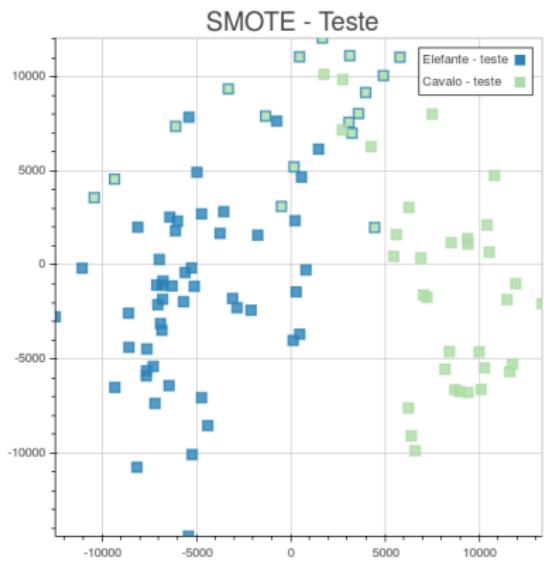
Figura : Comparação dos exemplos de treinamento da geração com

Geração de imagens artificiais e quantização aplicadas a problemas de classificação

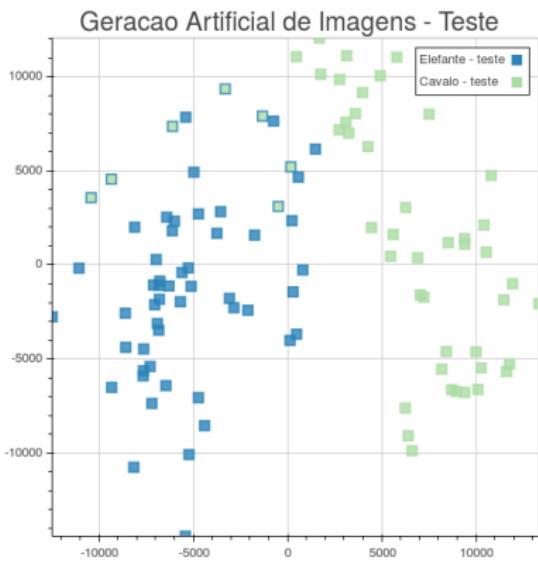
ICMC/USP

62/78

Experimento



(a) Smote



(b) Geração artificial

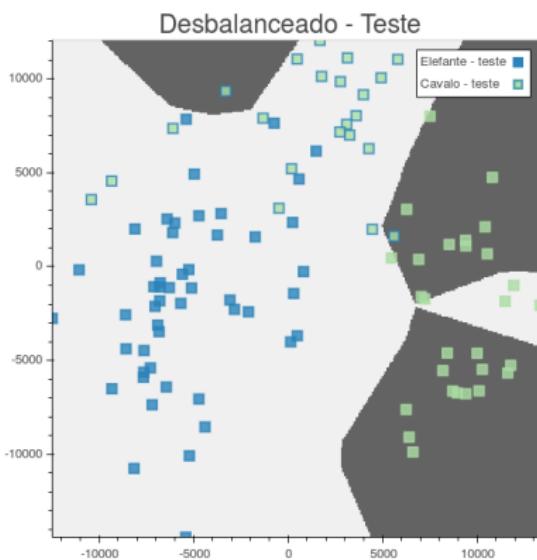
Figura : Resultado do teste da classificação com K-NN com $K = 1$ após

Geração de imagens artificiais e quantização aplicadas a problemas de classificação

ICMC/USP

63/188

Experimento



(a) Desbalanceado

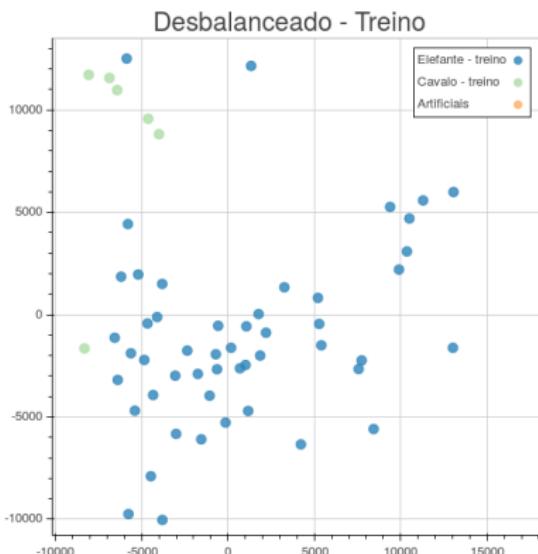
SMOTE - Teste



Geracao Artificial de Imagens - Teste



Experimento



SMOTE - Treino

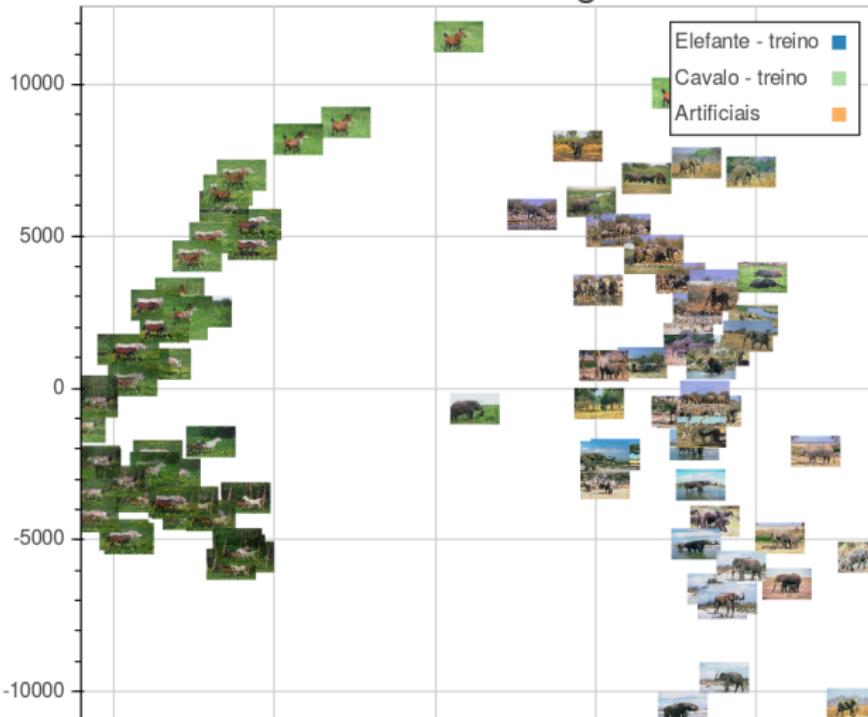


Geracao Artificial de Imagens - Treino



Experimento

Geracao Artificial de Imagens - Treino



Experimento

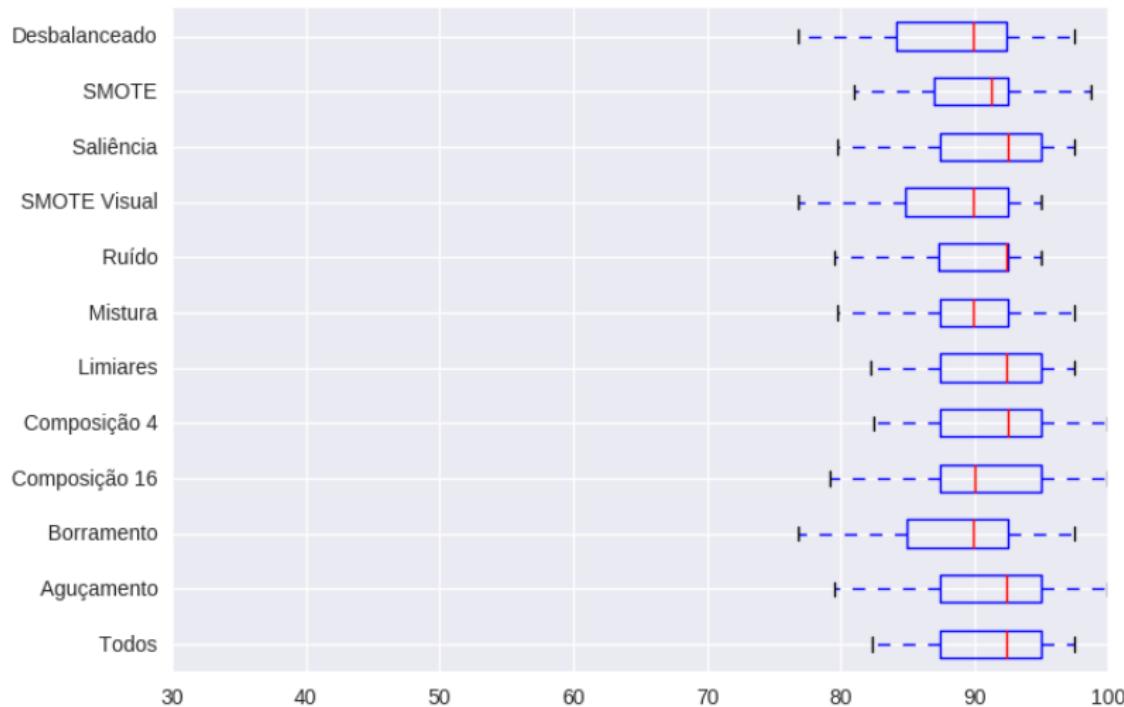


Figura : Conversão em escala de cinza com *Gleam* e ACC como método

Experimento

Tabela : Resultados de *F1-Score* para as classes *Horse* e *Elephant*, utilizando *Gleam* como método para conversão em escala de cinza e ACC para extração de características. Nota-se que o método de geração baseado em Composição 4 obteve maior valor de *F1-Score*.

Gleam & ACC	Média	Desvio Padrão
Todos	91.090913	4.559066
Aguçamento	91.002678	4.907016
Borramento	89.394500	5.103498
Composição 16	90.934305	4.399334
Composição 4	91.773528	4.909852
Limiares	90.893133	5.285833
Mistura	90.177055	4.409787
Ruído	89.337770	5.169757

Experimento



(a) Imagem gerada

Figura : A imagem gerada apresenta uma *composição* de quatro imagens da classe *Elephant*.

Fonte: *Elaborado pela autora.*

Experimento

Para o resultado da combinação dos melhores métodos de conversão em escala de cinza e extração de características, o teste *post-hoc* HSD de Tukey revelou que não há diferença estatística entre a base desbalanceada e o SMOTE ($p\text{-value} = 0.2073$). Mas indicou que existe uma significância entre o desbalanceamento e a geração artificial ($p\text{-value} = 0.0062$). Isso significa que o melhor método para rebalancear essas classes é a geração artificial utilizando o método de *misturas* de duas imagens. Ainda de acordo com o teste, não há evidência estatística da relevância do resultado da combinação de maior variância. Portanto, todos os próximos experimentos relatam apenas os resultados da melhor combinação.

Experimento

Tabela : *Ranking* dos métodos de rebalanceamento ao acumular os resultados de todos os experimentos. Esse valor é dado pela soma da posição de cada método em relação ao *F1-Score*, em ordem ascendente.

Cenários de duas classes	Cenário Multiclasses	Todos
Aguçamento (16)	SMOTE (13)	Limiares (35)
Limiares (17)	Mistura (14)	Mistura (39)
Saliência (22)	Limiares (18)	SMOTE (42)
Todos (25)	Todos (22)	Aguçamento (43)
Mistura (25)	Saliência (24)	Saliência (46)
Composição 4 (29)	Aguçamento (27)	Todos (47)
SMOTE (29)	Composição 4 (28)	Composição 4 (57)
Composição 16 (37)	Ruído (28)	Composição 16 (65)

Experimento

Tabela : Apresenta a média dos *F1-Scores* para cada método, ordenada pela coluna de todos os experimentos. É possível verificar que, no cenário multiclasses, apesar de ter sido o melhor método em relação à sua posição, o SMOTE apresentou piores resultados mesmo comparando com as bases desbalanceadas.

Métodos	Cenários de duas classes	Cenário Multiclasses
Aguçamento	84,473575	74,817654
Limiares	84,332408	74,472474
Saliência	84,172238	74,248645
Composição 4	83,123738	74,667785
Composição 16	82,977850	74,581912
Mistura	83,124582	74,045887

Resultados - Rede de Convolução

<http://caffe.berkeleyvision.org/>

Tabela : Treinamento das classes praia e montanha da base COREL-1000.

Bases	Medida F1
Original não balanceada	0.708
Desbalanceada em 50%	0.577
Rebalanceada	0.677

Artigo publicado na Neurocomputing

Ponti, M.; Nazaré, T; Thumé, G. **Image quantization as a dimensionality reduction procedure in color and texture feature extraction**, submitted to Neurocomputing, 2014.

Neurocomputing 173 (2014) 395–396

 Contents lists available at ScienceDirect
Neurocomputing
journal homepage: www.elsevier.com/locate/neucom



Image quantization as a dimensionality reduction procedure in color and texture feature extraction

Moacir Ponti ^a, Tiago S. Nazaré, Gabriela S. Thumé
Instituto de Ciências Matemáticas e de Computação/Universidade de São Paulo São Carlos, 13560-900 SP Brazil

ARTICLE INFO

Article history:
Received 2 July 2014
Received in revised form
8 April 2015
Accepted 14 April 2015
Available online 1 September 2015

Keywords:
Image quantization
SIFT
Compact features extraction

ABSTRACT

The image-based visual recognition pipeline includes a step that converts color images into images with a single channel, obtaining a color quantized image that can be processed by feature extraction methods. In this work we propose a dimensionality reduction procedure based on image quantization to reduce memory consumption and processing time in image-based visual recognition systems. We show that different quantization methods produce very different results in terms of accuracy. While compared with more complex methods, this procedure allows the feature extraction step to be faster and more compact, resulting in a more efficient and accurate visual recognition system. The results indicate that quantization simplify images before feature extraction and dimensionality reduction, producing more compact vectors and reducing system complexity.

© 2015 Elsevier B.V. All rights reserved.

Trabalhos futuros

- ▶ Analisar a memória associativa aprendida com uma máquina de Boltzmann restrita.
 - ▶ Escolher para qual imagem original utilizar, ao invés do método aleatório utilizado nos resultados preliminares;
 - ▶ Verificação da relevância das imagens geradas.

Agradecimentos

Moacir Antonelli Ponti

João do Espírito Santo Batista Neto



*Conselho Nacional de Desenvolvimento
Científico e Tecnológico*



Referências I

Geração de imagens artificiais e quantização aplicadas a problemas de classificação

Gabriela Salvador Thumé

Orientador: Prof. Dr. Moacir Antonelli Ponti

Co-orientador: Prof. Dr. João do Espírito Santo Batista Neto

Instituto de Ciências Matemáticas e de Computação
Universidade de São Paulo

29 de abril de 2016

